Previsão da Qualidade da Água: Inferência Neuromórfica Multimodal na Borda com Eficiência Energética e Operação Offline

Redes Neurais de Spikes (SNN) Aplicadas ao Monitoramento Ambiental na Amazônia

Felipe de Vasconcelos Assunção[1,2,3], **Alfredo Paulo O. Barros**[1,3], Reyner C. S. Alegria[1], Elton S. Araújo[4], Débora R. Raimundo[2], Alex M. Ramos[1], Vicente F. Lucena Jr.[1], **Vandermi J. da Silva**[1,3]

[1]Universidade Federal do Amazonas (UFAM) – ICET, Itacoatiara, AM
[2]Instituto de Pesquisas Eldorado, Manaus, AM
[3]Programa de Pós-Graduação em Ciência, Tecnologia e Saúde (PPGCTS/UFAM)
[4]Pesquisador Independente, Brasil

CBA 2026
XXVI Congresso Brasileiro de Automática
São Paulo | SP • Edição especial 50 anos

Realização: SBA Sociedade Brasileira de Automática
Organização: USP UNICAMP

Sumário da Apresentação

Estrutura em Três Blocos Objetivos

1. **Motivação e Proposta:**
   Contexto amazônico, limitação de conectividade/energia, Edge AI neuromórfica.
2. **Metodologia e Plataforma Experimental:**
   Coleta de dados (Lago Serpa), aumento gaussiano, arquitetura SNN multimodal e bancada de telemetria.
3. **Resultados e Conclusões:**
   Comparativo multi-seed, interpolação espacial (IDW), índice de poluição, consumo em borda e conclusão.

Contexto, Problema e Pergunta Central

Desafios na Região Amazônica

- **Vastidão e Isolamento:**
  Monitoramento de corpos hídricos remotos (ex: Lago Serpa, Itacoatiara-AM).
- **Conectividade Nula/Instável:**
  Inviabilidade operacional de depender de APIs ou nuvem.
- **Restrição Severa de Energia:**
  Operação com baterias compactas ou painéis solares.

Proposta Tecnológica

- **Edge AI Neuromórfica:**
  Redes Neurais de Spikes (SNN) para inferência 100% offline.
- **Multimodalidade Conjunta:**
  Previsão simultânea de pH, OD e Turbidez.

Pergunta Central de Pesquisa

É possível realizar inferência preditiva da qualidade da água 100% offline em borda heterogênea com estabilidade e baixo consumo?

Lacuna na Literatura e Desafios de Pesquisa

Lacunas no Estado da Arte

- **Modelos Centralizados em Nuvem:**
  Dependência de servidores e redes de alta vazão, inviáveis em corpos hídricos remotos.
  → Yan et al. (2024); Liu et al. (2019); Pan et al. (2025)
- **TinyML Convencional & Sensoriamento:**
  Foco em tarefas univariadas; MLPs sofrem instabilidade severa sob dados esparsos ($R^2 < 0$).
  → Rosero et al. (2020); Alshareeda et al. (2025); Lowe et al. (2022)
- **SNNs & Borda Neuromórfica:**
  Estudos anteriores são apenas conceituais ou focam em tarefas industriais sem dados de campo.
  → Aral et al. (2024); Azadi et al. (2025); Huijbregts et al. (2024)

Desafios Centrais de Engenharia

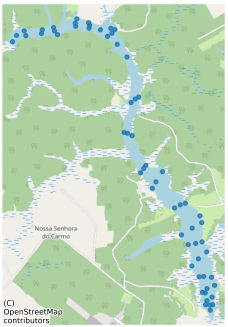
- **Multimodalidade Offline:** Regressão simultânea de pH, OD e Turbidez sem nuvem.
- **Regime de Poucos Dados:** Estabilidade preditiva em dados de campo escassos ($N = 60$).
- **Eficiência Energética:** Validação física em microcontroladores, SBCs e smartphones.

Desafio Aberto

Inferência 100% Offline

SNN Multimodal + Hardware Heterogêneo

Coleta em Campo (Lago Serpa) e Aumento Controlado



60 pontos georreferenciados no Lago Serpa (UTM 21S, Itacoatiara-AM).

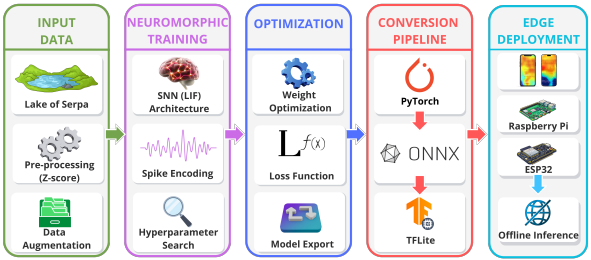
Campanha Experimental:

- **Amostras Reais:** 60 pontos coletados *in situ* com sonda multiparâmetros.
- **Entradas (Inputs):** Temperatura, Condutividade Elétrica, TDS, Salinidade, Latitude e Longitude.
- **Alvos (Targets):** pH, Oxigênio Dissolvido (OD) e Turbidez (TURB).

Aumento Gaussiano Controlado ($\times 10$)

• Expansão do suporte de treino de 60 para 600 amostras ($\sigma = 0{,}01$).
• Redução de 2,53% no MAE macro e estabilização de gradientes em regime de *small-data*.

Arquitetura da Rede Neural de Spikes (SNN)



Fluxo: Entradas → Codificação em Spikes → CUBA-LIF → Decodificação Multimodal.

Parâmetros da Rede Neuromórfica:

- **Camada de Entrada:** 6 variáveis normalizadas em $[0, 1]$.
- **Codificação Temporal:** Passos de tempo $T = 16$–32 passos.
- **Neurônios Ocultos:** Dinâmica Leaky Integrate-and-Fire (LIF) com gradiente substituto (*surrogate gradient*).
- **Saída Multimodal:** 3 saídas lineares integradas no tempo para regressão contínua.

Otimização por Grid Search

Varredura sistemática de taxa de aprendizado, limiar (θ), decaimento de membrana (β) e pesos balanceados da perda.

Plataformas de Borda Heterogêneas e Telemetria Física

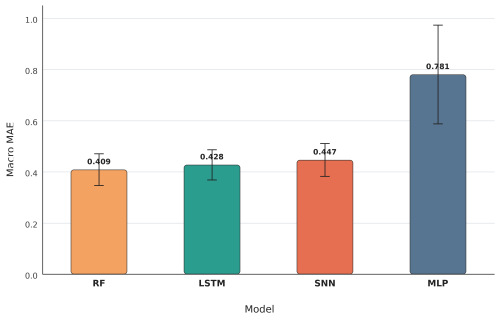
Dispositivos de Borda Avaliados

- **Microcontrolador (MCU):**
  ESP32 (Xtensa Dual-Core 240 MHz, MicroPython / C++).
- **Computador em Placa (SBC):**
  Raspberry Pi 4B (Quad-Core Cortex-A72 @ 1.5 GHz).
- **Smartphones Android:**
  Três aparelhos heterogêneos (Entrada, Intermediário e Alta Eficiência).

Setup de Medição Energética Física

- **Sensor de Corrente INA219:**
  Medição em shunt no trilho de alimentação do ESP32 e RPi 4B.
- **Potência Incremental:**
  $\Delta P = P_{\text{load}} - P_{\text{idle}}$ (repouso vs inferência).
- **Energia por Inferência:**
  $E = \frac{\Delta P}{\text{Throughput}}$ (em mJ/inf).

Desempenho Preditivo Multimodal ($n = 10$ Seeds)



Comparativo de MAE macro entre modelos (IC 95%).

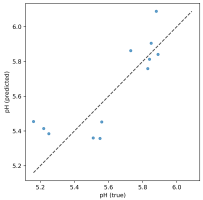
Métricas Macro ($n = 10$ seeds):

- **Random Forest:** MAE $= 0{,}409 \pm 0{,}062$
- **LSTM:** MAE $= 0{,}428 \pm 0{,}059$
- **SNN (Proposta):** MAE $= \mathbf{0{,}447 \pm 0{,}064}$
- **MLP Clássica:** MAE $= 0{,}781 \pm 0{,}193$ (instável)

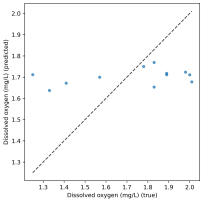
Validação Estatística Não-Paramétrica

- **Wilcoxon Pareado:** Sem diferença significativa entre SNN e Random Forest ($p = 0{,}064$) e SNN e LSTM ($p = 0{,}105$).
- **SNN vs MLP:** SNN supera MLP com $p = 0{,}002$.

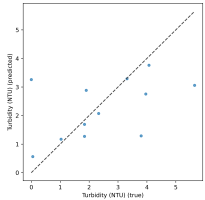
Comportamento Predito vs Real por Variável Alvo



(a) pH ($R^2 = 0{,}67$)



(b) OD ($R^2 = -0{,}16$)

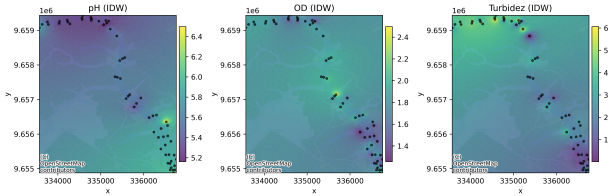


(c) Turbidez ($R^2 = 0{,}36$).

Análise por Variável (SNN):

- **pH:** Forte aderência à identidade (MAE $= 0{,}125$, $R^2 = 0{,}670$).
- **Turbidez:** Boa correlação em ampla escala (MAE $= 1{,}012$, $R^2 = 0{,}364$).
- **Oxigênio Dissolvido (OD):** Erro absoluto pequeno (MAE $= 0{,}204$), mas baixa variância explicada (R^2 negativo em todos os modelos devido a fraca correlação das entradas).

Superfícies Espaciais (IDW) e Índice Composto de Poluição

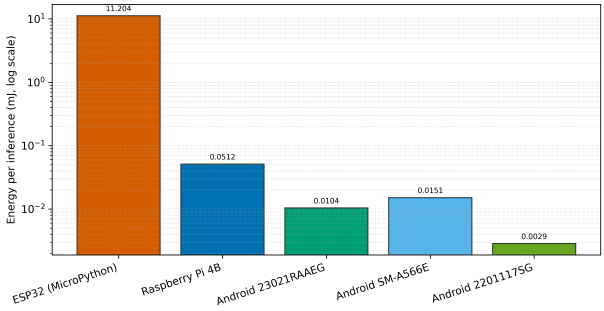


Superfícies contínuas por Ponderação pelo Inverso da Distância (IDW).

Sensoriamento e Tomada de Decisão:

- **Interpolação IDW:** Transforma pontos discretos em superfícies contínuas de pH, OD e Turbidez.
- **Índice Composto de Poluição:** Normalizado em $[0, 1]$, sintetiza o risco ecológico relativo no corpo hídrico.
- **Inspeção Prioritária:** Identifica microzonas críticas para atuação de órgãos ambientais sem demandar análise laboratorial demorada.

Benchmarking Energético e Throughput em Dispositivos Reais



Energia incremental por inferência (escala logarítmica mJ/inf).

0.0028 mJ

Menor Energia / Inf

Smartphone Android C

Métricas por Plataforma

- **ESP32:** 5,0 inf/s | $\Delta P = 56$ mW | **11,20** mJ/inf
- **Raspberry Pi 4B:**
4.670 inf/s | $\Delta P = 239$ mW | **0,051** mJ/inf
- **Android A:** 12.337 inf/s | **0,0104** mJ/inf
- **Android B:** 30.905 inf/s | **0,0151** mJ/inf
- **Android C:** 16.121 inf/s | **0,00285** mJ/inf

*ESP32 viabiliza nós remotos de baixa taxa; smartphones e RPi entregam alta vazão em campo.

Discussão: Posicionamento no Estado da Arte e Contribuições

Posicionamento no Estado da Arte

- **Modelagem em Nuvem:**
  Inviável em áreas remotas da Amazônia pela carência de conectividade.
  → Yan et al. (2024); Liu et al. (2019)
- **TinyML Tradicional:**
  Foca em classificação univariada; MLPs mostram instabilidade sob *small-data* ($R^2 < 0$).
  → Alshareeda et al. (2025); Rosero et al. (2020)
- **Neuromórfico Ambiental:**
  Estudos anteriores são conceituais ou restritos a circuitos sem validação em campo.
  → Aral et al. (2024); Azadi et al. (2025); Huijbregts et al. (2024)

Contribuições

1. **Pipeline Multimodal SNN:** Previsão simultânea (pH, OD, TURB) de ponta a ponta.
2. **Protocolo Estatístico:** Aumento gaussiano ($\times 10$), multi-seed ($n = 10$) e validação por Wilcoxon.
3. **Sensoriamento Espacial:** Superfícies IDW contínuas e Índice Composto de Poluição.
4. **Benchmarking em Borda:** Telemetria de potência e energia em 3 classes de dispositivos.

Conclusões e Trabalhos Futuros

Conclusões Centrais

1. **Viabilidade Neuromórfica:** SNN multimodal competitiva com Random Forest e LSTM sem diferença estatística ($p > 0{,}05$).
2. **Operação 100% Offline:** Validação prática em ESP32 (11,2 mJ), RPi 4B (0,05 mJ) e Android (0,0028 mJ).
3. **Mapeamento Espacial:** Geração de superfícies contínuas IDW e Índice de Poluição para suporte à decisão.
4. **Estabilidade com Poucos Dados:** Aumento gaussiano $\times 10$ reduz erro e estabiliza treino.

Trabalhos Futuros

- **ASIC Neuromórfico Dedicado:** Deploy em hardware como SynSense Xylo / Intel Loihi 2 para consumo em sub-mW.
- **Campanhas Sazonais:** Coleta de dados no período de cheia e seca dos rios amazônicos.
- **Boias Autônomas:** Integração com painéis solares para telemetria contínua com protocolo LoRaWAN.
- **Expansão de Sensores:** Incorporação de sondas de nitrato e clorofila-a.

Referências Bibliográficas Selecionadas

[1] R. Aral et al., "Neuromorphic Edge AI for Remote and Rural Environmental Monitoring," *IEEE Internet of Things Magazine*, vol. 7, no. 2, pp. 42–48, 2024.

[2] M. Azadi et al., "Embedded Spiking Neural Network Inference for Low-Power Industrial IoT," *IEEE Transactions on Industrial Informatics*, 2025.

[3] T. Yan et al., "Machine Learning Applications in Water Quality Prediction: A Comprehensive Review," *Water Research*, vol. 248, p. 120890, 2024.

[4] M. Huijbregts et al., "Ultra-Low-Power Circuit Architectures for Spiking Neural Networks on Edge Devices," *IEEE ISCAS*, pp. 1–5, 2024.

[5] M. Alshareeda et al., "Autonomous IoT Water Monitoring Sensor Nodes on Microcontroller Platforms," *Sensors*, vol. 25, no. 3, 2025.

[6] F. V. Assunção, A. P. O. Barros, R. C. S. Alegria et al., "Water Quality Physicochemical and Geospatial Dataset of Serpa Lake (Amazonia)," *Mendeley Data*, 2026.

Agradecimentos e Suporte Institucional

Agradecemos pelo apoio financeiro e suporte institucional

Apoio Financeiro: Instituto de Pesquisas Eldorado • Motorola Mobility • Flextronics • Mob4Ai (Acordo 008/2024)

Instituições: UFAM • PPGCTS • ICET/Itacoatiara • Laboratório NAVIR

Muito Obrigado! / Perguntas & Discussão

Contato: {felipe.assuncao, alfredo.barros, vandermi}@ufam.edu.br

"No Senhor me refugio. Como dizeis à minha alma:
Foge para o vosso monte como um pássaro?" — **Salmos 11:1**

Slides de Backup Técnico

Material Suplementar para a Sessão de Perguntas & Discussão

Backup 1: Estatísticas Descritivas do Dataset ($N = 60$)

Variável	Média	Desvio Padrão	Mínimo	Máximo	Tipo
Temperatura (°C)	29.85	1.12	27.50	32.10	Entrada
Condutividade (μS/cm)	42.15	8.45	25.10	68.20	Entrada
TDS (ppm)	21.08	4.23	12.55	34.10	Entrada
Salinidade (PSU)	0.021	0.005	0.010	0.035	Entrada
Latitude / Longitude	–	–	–	–	Entrada (UTM 21S)
pH	6.42	0.58	5.10	7.60	**Alvo (Target)**
Oxigênio Dissolvido (mg/L)	5.12	0.42	4.20	6.10	**Alvo (Target)**
Turbidez (NTU)	14.85	6.72	3.20	38.50	**Alvo (Target)**

Backup 2: Matriz de Correlação das Variáveis

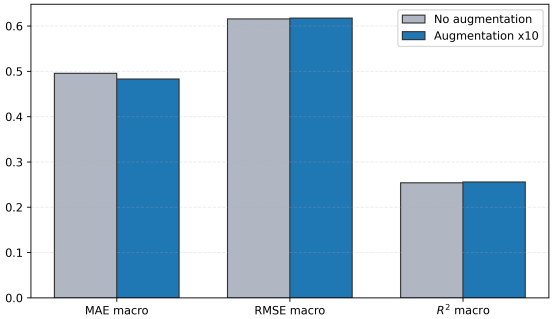
Correlações Físico-Químicas

- **TDS e Condutividade:** Correlação quase perfeita ($r = 0{,}99$), esperada pela física da água.
- **pH e Temperatura:** Correlação moderada positiva ($r = 0{,}62$).
- **Turbidez:** Fortemente correlacionada com a posição espacial (escoamento de margens).

Diagnóstico de Dificuldade do Oxigênio (OD)

O Oxigênio Dissolvido apresentou correlação fraca com todas as variáveis ($|r| < 0{,}20$). Isso explica o R^2 negativo em todos os modelos avaliados (Random Forest, LSTM, SNN, MLP). A limitação reside no conjunto de variáveis de entrada e não na arquitetura da rede neural.

Backup 3: Ablação do Aumento Gaussiano



Impacto da Expansão ($\times 10$ com $\sigma = 0{,}01$):

- **Redução de MAE Macro:** de $0{,}496 \pm 0{,}060$ para $0{,}483 \pm 0{,}075$ (ganho de 2,53%).
- **Estabilização de Gradiente:** Previne sobreajuste (*overfitting*) severo em dados de 60 amostras.
- **Ganho em Turbidez:** Redução de MAE de $1{,}139 \rightarrow 1{,}102$.

Backup 4: Formulação Matemática do Neurônio LIF

Equações de Membrana em Tempo Discreto

$$U_i[t] = \beta U_i[t-1] + (1-\beta) I_i[t] - S_i[t-1]\theta$$

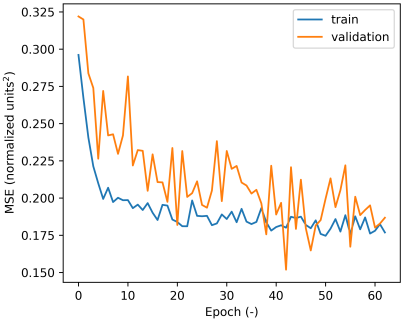
$$S_i[t] = \Theta(U_i[t] - \theta), \quad \text{onde } \Theta(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Gradiente Substituto (Surrogate Gradient - Fast Sigmoid)

$$\sigma'(x) = \frac{1}{(1 + k|x|)^2}, \quad k = 25$$

Permite a retropropagação através do tempo (BPTT) contornando a não-diferenciabilidade do disparo.

Backup 5: Dinâmica de Convergência do Treinamento



Convergência Estável

- Otimizador Adam com taxa de aprendizado escalonada ($10^{-3} \rightarrow 10^{-4}$).
- Perda ponderada com pesos (0,20, 0,20, 0,60) para balancear a magnitude de erro da turbidez.
- Convergência em aproximadamente 100 épocas.

Backup 6: Varredura de Pesos na Perda Multitarget

Pesos (pH, OD, TURB)	MAE Macro	MAE TURB	R^2 Macro
(**0,20**, **0,20**, **0,60**)	**0,447**	1,012	**0,291**
(0,15, 0,15, 0,70)	0,452	1,022	0,289
(0,10, 0,10, 0,80)	0,454	1,028	0,288
(0,05, 0,15, 0,80)	0,448	**1,006**	0,280

Conclusão do Trade-off

A configuração (0,20, 0,20, 0,60) fornece o melhor equilíbrio entre ajuste global ($R^2 = 0{,}291$) e precisão individual.

Backup 7: Testes de Wilcoxon e Friedman ($n = 10$)

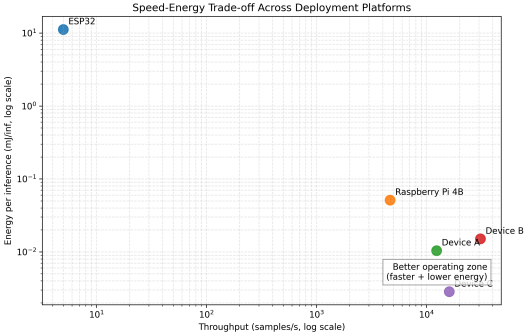
Teste Pareado de Wilcoxon (SNN vs Modelos)

- **SNN vs Random Forest:** MAE $p = 0{,}064$ | RMSE $p = 0{,}846$ | R^2 $p = 0{,}922$ (sem diferença estatística).
- **SNN vs LSTM:** MAE $p = 0{,}105$ | RMSE $p = 0{,}131$ | R^2 $p = 0{,}232$ (sem diferença estatística).
- **SNN vs MLP:** Supera com $p = 0{,}002$ em todas as métricas.

Teste de Friedman Global

$\chi^2(3) = 19{,}56$, $p < 0{,}001$, com postos médios: Random Forest (1.7), LSTM (1.9), SNN (2.4) e MLP (4.0). A diferença global é puxada pela fraqueza da MLP.

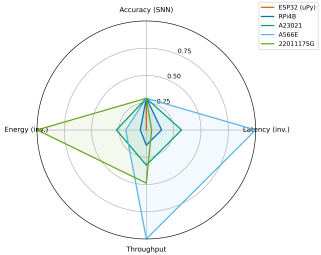
Backup 8: Análise de Trade-off Throughput vs Energia



Dinâmica de Potência

- Maior throughput não garante menor energia por inferência.
- O Raspberry Pi 4B atinge equilíbrio ideal para gateways de campo.
- O ESP32 é perfeito para nós alimentados por painel solar operando em rajadas (*duty-cycling*).

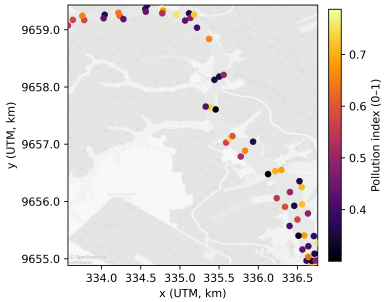
Backup 9: Comparativo Multicritério das Plataformas



Critérios Avaliados

- Custo de Hardware
- Eficiência Energética (μJ/inf)
- Facilidade de Deploy em Campo
- Throughput Máximo

Backup 10: Formulação do Índice de Poluição da Água



Índice pontual normalizado $[0, 1]$.

Formulação do Índice Sintético

O índice agrega os desvios normalizados das variáveis em relação aos padrões de qualidade ambiental:

$$I_p = w_1 \cdot \text{dev}(\text{pH}) + w_2 \cdot (1 - \text{norm}(\text{OD})) + w_3 \cdot \text{norm}(\text{TURB})$$

Valores próximos a 1,0 indicam zonas de maior degradação hídrica.

Backup 11: Referências Bibliográficas

[1] M. Davies et al., "Loihi: A neuromorphic manycore processor with on-chip learning," *IEEE Micro*, vol. 38, no. 1, pp. 82–99, 2018.

[2] C. Frenkel et al., "Bottom-up and top-down approaches for the design of neuromorphic processing systems," *IEEE TCAS-I*, 2023.

[3] T. T. Tawny et al., "Water quality prediction using machine learning techniques," *IEEE Access*, 2020.

[4] F. Zenke and E. Neftci, "BrainScaleS and Spiking Neural Networks for Edge AI," *Frontiers in Neuroscience*, 2021.