Predição da Qualidade da Água: Inferência Neuromórfica Multimodal Offline com Consciência Energética na Borda ⋆

Felipe de Vasconcelos Assunção [*,***,****]
Alfredo Paulo Oliveira Barros [*,****] **Reyner Carlos Silva Alegria** [*]
Elton dos Santos Araújo [**] **Débora Romano Raimundo** [***]
Alex Martins Ramos [*] **Vicente Ferreira de Lucena Junior** [*]
Vandermi João da Silva [*,****]

[*] *Universidade Federal do Amazonas (UFAM), Instituto de Ciências Exatas e Tecnologia (ICET), Itacoatiara, Brasil (e-mail: {felipe.assuncao, alfredo.barros, reyner.alegria, alexmartins, vicente, vandermi}@ufam.edu.br).*
[**] *Pesquisador Independente, Brasil (e-mail: elton_araujo_@hotmail.com).*
[***] *Instituto de Pesquisas Eldorado, Brasil (e-mail: debora.raimundo@eldorado.org.br, felipe.assuncao@eldorado.org.br).*
[****] *Programa de Pós-Graduação em Ciência, Tecnologia e Saúde (PPGCTS), Brasil.*

Resumo: Este trabalho apresenta um pipeline neuromórfico centrado em Edge AI para a predição multimodal da qualidade da água em um cenário remoto da Amazônia. O objetivo central é a implantação totalmente offline em hardware restrito, evitando a dependência de nuvem sob conectividade limitada e orçamentos de energia reduzidos. Uma rede neural pulsada (SNN) é utilizada para predizer conjuntamente pH, oxigênio dissolvido e turbidez a partir de entradas físico-químicas georreferenciadas coletadas em uma campanha de campo com 60 amostras georreferenciadas. Para melhorar a estabilidade em condições de poucos dados, aplicamos aumento de dados gaussiano controlado (expandindo o suporte de treinamento em dez vezes, para 600 amostras) e otimizamos o modelo por meio de busca em grade sistemática sobre passos temporais, taxa de aprendizado, limiar, decaimento e tamanho da camada oculta. A SNN multimodal resultante é avaliada com protocolos de múltiplas sementes reportados com intervalos de confiança de 95% e testes de significância não paramétricos (Wilcoxon pareado exato e Friedman) e, em seguida, implantada em plataformas de borda heterogêneas (ESP32, Raspberry Pi e dispositivos Android). Reportamos vazão, latência e energia incremental por inferência usando medições em repouso/carga, incluindo telemetria baseada em INA219 quando aplicável. Os resultados mostram que, embora Random Forest e LSTM possam alcançar menor erro macro médio, a SNN permanece competitiva e operacionalmente robusta para cenários de borda, viabilizando inferência offline prática em hardware das classes microcontrolador, SBC e smartphone. De forma geral, o estudo demonstra que a Edge AI neuromórfica é uma estratégia viável para o monitoramento ambiental autônomo em regiões com restrições de conectividade e energia.

Palavras-chave: Redes Neurais Pulsadas; Edge AI; Avaliação Energética; Predição da Qualidade da Água; Modelagem Multimodal; Inferência Offline.

1. INTRODUÇÃO

O monitoramento da qualidade da água em áreas remotas da Amazônia é limitado pela infraestrutura esparsa, pelo alto custo logístico das campanhas de campo e pela conectividade de rede intermitente. A implantação de Edge AI é a motivação central deste trabalho: a inferência local, totalmente offline, é necessária para manter o monitoramento funcional sob comunicações instáveis e orçamentos de energia limitados. Nesse contexto, a dependência contínua de inferência em nuvem é operacionalmente frágil e energeticamente cara, especialmente em implantações alimentadas por bateria e campanhas de longa duração. Ao mesmo tempo, variáveis de qualidade da água como pH, oxigênio dissolvido (OD) e turbidez são altamente

⋆ Os autores agradecem o apoio financeiro do Instituto de Pesquisas Eldorado, da Motorola Mobility Comércio de Produtos Eletrônicos Ltda, da Flextronics da Amazônia Ltda e do projeto de PD&I "Mob4Ai – Advanced Artificial Intelligence for Neuromorphic Mobile Systems" (Convênio nº 008/2024, nos termos do Decreto nº 10.521/2020 e da Lei Federal nº 8.387/1991).

relevantes para a triagem ambiental e a mitigação de riscos à saúde pública.

Pipelines convencionais de aprendizado de máquina podem oferecer forte desempenho preditivo, mas muitos são projetados para execução centrada em servidores e não tratam diretamente as restrições energéticas na borda. Modelos neuromórficos baseados em redes neurais pulsadas (SNNs, do inglês *spiking neural networks*) oferecem uma alternativa orientada a eventos, compatível com sistemas embarcados de baixo consumo; contudo, evidências práticas em fluxos reais de sensoriamento ambiental ainda são limitadas, particularmente quando se combinam predição multimodal e avaliação energética em nível de plataforma.

Este artigo propõe e avalia um pipeline SNN multimodal offline para predição da qualidade da água em um cenário de campo amazônico, incluindo implantação de ponta a ponta e análise energética multiplataforma. O estudo integra processamento de dados, treinamento de modelos, interpretação geoespacial e inferência embarcada em hardware heterogêneo (ESP32, Raspberry Pi e dispositivos Android).

As principais contribuições deste trabalho são quatro: (i) o desenvolvimento de um pipeline de predição da qualidade da água baseado em SNN multimodal, projetado para implantação offline na borda; (ii) a criação de um conjunto de dados georreferenciado aumentado, derivado de medições de campo no Lago do Serpa; (iii) uma avaliação comparativa de latência–energia em plataformas heterogêneas, incluindo ESP32, Raspberry Pi e dispositivos Android; e (iv) um protocolo de avaliação estatisticamente fundamentado para regressão ambiental com poucos dados, combinando avaliação com sementes repetidas, intervalos de confiança e testes de significância não paramétricos. Para além da avaliação energética, a contribuição científica reside em demonstrar, de ponta a ponta, que a regressão neuromórfica multimodal de alvos físico-químicos de qualidade da água é viável desde a aquisição em campo até a inferência totalmente offline em três classes distintas de hardware de borda — uma combinação ainda não reportada para o monitoramento de água doce na região amazônica.

2. TRABALHOS RELACIONADOS

2.1 Predição da Qualidade da Água

A predição orientada a dados de indicadores de qualidade da água tem sido amplamente explorada com RNAs, modelos baseados em árvores e arquiteturas recorrentes. Revisões e estudos recentes reportam o uso consistente de variáveis físico-químicas e de contexto geoespacial para prever pH, OD, turbidez e indicadores compostos Yan et al. (2024); Ahmed et al. (2019); Al-Adhaileh and Alsaade (2021); Pan et al. (2025). Abordagens baseadas em LSTM são comuns onde os registros temporais são densos Liu et al. (2019); Pyo et al. (2023); Qi et al. (2020), enquanto métodos híbridos e de comitês melhoram a robustez sob comportamento não linear e regimes de amostragem limitados Wu and Wang (2022); Chadalavada et al. (2025); Kalaivanan and Vellingiri (2022); Palani et al. (2008).

Além da escolha do modelo, uma distinção importante na literatura é o objetivo operacional: máxima acurácia preditiva em infraestrutura centralizada versus robustez sob sensoriamento ruidoso, amostragem esparsa e restrições de campo — uma distinção crítica para águas interiores, onde o comportamento do modelo é afetado pela heterogeneidade local, pela sazonalidade e pela incerteza de medição Yan et al. (2024); Lowe et al. (2022); Rahu et al. (2023).

2.2 Edge AI e Avaliação Energética

Em implantações de IoT ambiental, o custo de inferência deve ser avaliado em conjunto com a qualidade preditiva. Trabalhos anteriores destacam a relevância do benchmarking em nível de plataforma e do projeto de modelos ciente do hardware Rosero-Montalvo et al. (2020); Zulkifli et al. (2022); Lamrini et al. (2024); El-Shafeiy et al. (2023). Estudos recentes de IA neuromórfica e energeticamente eficiente indicam que modelos orientados a eventos podem ser atraentes para cenários restritos, mas as evidências de implantação em hardware de borda heterogêneo ainda estão em desenvolvimento Aral (2024); Azadi et al. (2025); Huijbregts et al. (2024); Aribe Jr. (2025). Essa lacuna motiva o presente trabalho: uma comparação unificada da qualidade de inferência multimodal offline e do comportamento de energia por inferência em múltiplas plataformas práticas.

A maioria dos estudos anteriores reporta métricas algorítmicas ou métricas de hardware isoladamente. Em contraste, a implantação em campo requer uma visão acoplada de latência, vazão e energia incremental sob transições realistas de repouso/carga. Consequentemente, o benchmarking multiplataforma deve ser interpretado como um resultado de sistemas, e não apenas como um resultado de modelo.

Posicionar este trabalho frente a estudos recentes de monitoramento ambiental neuromórfico esclarece sua novidade. Aral (2024) discutem a promessa da Edge AI neuromórfica para monitoramento rural em nível conceitual, sem implantação em campo; Azadi et al. (2025) demonstram inferência neuromórfica embarcada para IoT industrial, mas não para regressão de qualidade da água; Huijbregts et al. (2024) tratam da eficiência de SNNs em nível de circuito; e Al-Shareeda et al. (2025) implantam monitoramento de água baseado em ESP32 sem modelos neuromórficos. Até onde sabemos, nenhum estudo anterior combina regressão SNN multimodal de alvos físico-químicos, dados de campo de um lago amazônico e energia por inferência medida em hardware das classes microcontrolador, SBC e smartphone em um único pipeline offline, que é a lacuna aqui abordada.

3. DESCRIÇÃO DO CONJUNTO DE DADOS

A campanha de campo foi conduzida em um ambiente de água doce na região amazônica (Itacoatiara, AM, Brasil), com pontos de amostragem georreferenciados distribuídos para capturar gradientes espaciais locais. O conjunto de dados inclui a posição em UTM 21S e variáveis físico-químicas usadas como entradas e saídas do modelo, e está publicamente disponível no Mendeley Data Vasconcelos Assunção et al. (2026). A cobertura espacial da campanha é mostrada na Fig. 1, e as estatísticas descritivas dos alvos de predição são reportadas na Tabela 2.

Tabela 1. Correlação de Pearson entre atributos de entrada e alvos (conjunto original, $n = 60$).

Atributo	pH	OD	TURB
x	0.75	−0.23	−0.67
y	−0.85	0.18	0.69
TEMP	−0.56	0.24	0.33
COR_A	−0.79	0.05	0.68
COR_V	−0.46	0.08	0.50

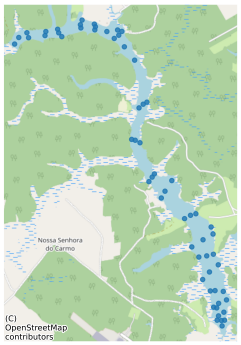


Figura 1. Localizações de amostragem sobre mapa-base OpenStreetMap (UTM 21S).

A coleta de dados seguiu um desenho espacialmente distribuído para representar diferentes microzonas do lago, em vez de amostrar repetidamente uma única coordenada, apoiando a interpretação espacial e o suporte à decisão local (mapas de interpolação e índices compostos de triagem). As medições foram consolidadas em uma estrutura tabular adequada à inferência orientada à borda e ao treinamento reprodutível.

3.1 Variáveis e Aquisição

Os atributos de entrada foram x, y, temperatura (TEMP), cor aparente em escala âmbar (COR_A) e índice visual de cor (COR_V). As variáveis-alvo foram pH, oxigênio dissolvido (OD) e turbidez (TURB). O conjunto de dados original de campo compreende 60 amostras georreferenciadas. O desenho amostral priorizou a representatividade espacial em detrimento da repetição temporal densa, de forma consistente com o objetivo de gerar superfícies espaciais interpretáveis.

A Tabela 1 reporta a correlação de Pearson entre cada atributo de entrada e cada alvo no conjunto original de 60 amostras. As coordenadas espaciais e os índices de cor estão fortemente associados ao pH ($r = -0{,}85$ para y; $r = -0{,}79$ para COR_A) e à turbidez ($r = 0{,}69$ e $r = 0{,}68$, respectivamente), indicando gradientes espaciais e ópticos exploráveis. Em contraste, o OD é fracamente correlacionado com todas as entradas disponíveis ($|r| \leq 0{,}24$), o que antecipa a maior dificuldade de predição desse alvo com o conjunto de atributos atual.

3.2 Aumento de Dados

Como o conjunto de dados original é pequeno ($n = 60$), aplicou-se aumento sintético com fator $\times 10$ usando perturbação gaussiana leve ($\sigma = 0{,}01$) no espaço normalizado, resultando em 600 amostras de suporte ao treinamento. Essa estratégia foi usada para estabilizar o treinamento e reduzir a sensibilidade à partição, preservando as distribuições marginais e a plausibilidade física. O conjunto aumentado é usado apenas como suporte ao treinamento e não representa medições de campo adicionais. A perturbação gaussiana foi adotada por sua transparência e baixo risco de distorção neste regime; estratégias alternativas de aumento para pequenos conjuntos tabulares — como interpolação no estilo SMOTE para regressão, mixup e abordagens generativas (p. ex., síntese baseada em cópulas ou GANs) — são candidatas naturais a uma comparação sistemática em trabalhos futuros.

Tabela 2. Estatísticas descritivas dos alvos no conjunto de dados original de campo.

Variável	Média	Desvio	Mín	Máx
pH	5.73	0.31	5.15	6.50
OD (mg/L)	1.86	0.32	1.26	2.52
Turbidez (NTU)	2.77	1.37	0.06	6.18

Para minimizar o risco de distorção, o aumento foi restrito a perturbações de baixa amplitude e avaliado com verificações distribucionais e análise de ablação: o objetivo foi aumentar a densidade local em torno das amostras observadas e melhorar a estabilidade da otimização entre partições aleatórias, e não criar dinâmicas sintéticas ausentes da campanha de campo.

Por fim, o conjunto de dados deve ser interpretado como um benchmark regional inicial, e não como uma representação hidrológica universal. A amostragem atual apoia a modelagem comparativa e a análise de implantação, enquanto a generalização externa mais ampla requer campanhas em múltiplas estações e sítios adicionais de água doce com diferentes perfis hidrodinâmicos e antrópicos. O pequeno tamanho amostral impõe limites metodológicos concretos: os valores absolutos das métricas carregam ampla incerteza, pequenas diferenças entre modelos podem não ser estáveis entre reamostragens e a amostragem de uma única estação não captura a sazonalidade hidrológica. Esses limites motivaram o protocolo conservador aqui adotado (sementes repetidas, intervalos de confiança e testes não paramétricos) e restringem o escopo das conclusões a afirmações comparativas e orientadas à implantação.

4. METODOLOGIA

4.1 Representação Multimodal de Entrada

Para evitar ambiguidade entre variáveis simbólicas e nomes de sensores, representamos cada observação por um vetor de atributos multimodal ordenado:

$$\mathbf{x} = [x, y, \mathrm{TEMP}, \mathrm{COR}_A, \mathrm{COR}_V] \in \mathbb{R}^5, \tag{1}$$

e um vetor-alvo de três saídas:

$$\mathbf{y} = [\mathrm{pH}, \mathrm{OD}, \mathrm{TURB}] \in \mathbb{R}^3. \tag{2}$$

Os atributos de entrada são normalizados antes da codificação em pulsos. Em seguida, aplicamos codificação por taxa (*rate coding*), de modo que cada escalar normalizado é convertido em um trem de pulsos ao longo de T passos de tempo, com probabilidade de disparo proporcional à sua magnitude. Isso produz uma representação temporal

compatível com a dinâmica LIF subsequente, preservando a estrutura multimodal da amostra original.

4.2 Arquitetura da SNN

O modelo segue uma SNN *feed-forward* com topologia $5 \to 64 \to 3$ e uma camada oculta de neurônios *leaky integrate-and-fire* (LIF), como ilustrado na Fig. 2. A atualização da membrana é

$$\mathbf{u}_{t+1} = \beta\,\mathbf{u}_t + \mathbf{W}\mathbf{s}_t - \theta\,\mathbf{z}_t, \tag{3}$$

onde β é o decaimento da membrana, θ é o limiar de disparo e $\mathbf{z}_t$ são os pulsos emitidos. A predição de saída é calculada por agregação temporal ao longo dos passos.

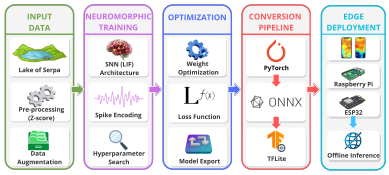


Figura 2. Arquitetura SNN multimodal proposta para inferência offline na borda.

A Figura 2 apresenta o fluxo completo de ponta a ponta: preparação dos dados de campo (normalização e aumento controlado), treinamento neuromórfico com neurônios LIF e busca de hiperparâmetros, otimização e exportação do modelo pelo caminho de interoperabilidade PyTorch→ONNX→TFLite, e implantação offline na borda em Android, Raspberry Pi e ESP32.

4.3 Protocolo de Treinamento

O treinamento usou o otimizador Adam e perda MSE ponderada com parada antecipada. Os hiperparâmetros foram selecionados por busca em grade sobre tamanho da camada oculta, taxa de aprendizado, passos temporais T, limiar e fator de decaimento. O espaço de busca completo foi: tamanho da camada oculta $\in \{32, 64, 96\}$, $T \in \{10, 15, 25\}$, taxa de aprendizado $\in \{0{,}0005;\ 0{,}001;\ 0{,}002\}$, decaimento $\beta \in \{0{,}90;\ 0{,}95\}$, limiar $\theta \in \{0{,}8;\ 1{,}0\}$ e ruído de aumento $\sigma \in \{0{,}01;\ 0{,}02;\ 0{,}03\}$, totalizando 324 configurações avaliadas pela perda de validação. A configuração selecionada foi: camada oculta 64, $T = 15$, taxa de aprendizado 0,002, $\beta = 0{,}95$, $\theta = 0{,}8$ e $\sigma = 0{,}01$. A avaliação usou sementes aleatórias repetidas e métricas macro (MAE, RMSE e R^2) sobre os três alvos. As dez execuções independentes com sementes distintas implementam validação por subamostragem aleatória repetida, que aproxima o comportamento da validação cruzada neste regime de poucos dados; um protocolo k-fold completo está planejado para o conjunto de dados ampliado em campanhas futuras.

4.4 Sensibilidade aos Hiperparâmetros

Os resultados da grade também fornecem uma análise de sensibilidade dos parâmetros LIF e da codificação temporal. Calculando a média marginal da perda de validação sobre as 324 configurações, a taxa de aprendizado teve o efeito mais forte (perda média de 0,826 em 0,0005 vs. 0,694 em 0,002). O limiar LIF mostrou preferência consistente por $\theta = 0{,}8$ em relação a $\theta = 1{,}0$ (0,747 vs. 0,769), enquanto o fator de decaimento teve influência menor (0,754 em $\beta = 0{,}90$ vs. 0,762 em $\beta = 0{,}95$). O parâmetro temporal T teve efeito fraco na acurácia (perda média de 0,766; 0,760 e 0,748 para $T = 10, 15, 25$), mas o custo de inferência cresce aproximadamente de forma linear com T, já que cada passo adicional implica mais uma propagação direta de pulsos. Portanto, nesta tarefa, T é primariamente um controle de energia–latência, e não de acurácia, e $T = 15$ foi mantido como ponto de operação equilibrado.

Como mostra a Fig. 3, as perdas de treinamento e validação diminuem rapidamente nas épocas iniciais e convergem para um platô estável com divergência limitada, indicando otimização consistente sem sobreajuste forte e apoiando o uso de parada antecipada neste regime de poucos dados.

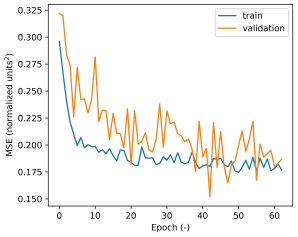


Figura 3. Perda de treinamento e validação (MSE) da SNN multimodal selecionada.

5. CONFIGURAÇÃO DA MEDIÇÃO DE ENERGIA

5.1 Instrumentação e Procedimento

ESP32 e Raspberry Pi: corrente e tensão foram amostradas a cada 500 ms usando o INA219. Duas janelas foram capturadas: repouso (N_{idle} amostras) e carga (N_{load} amostras) durante a execução do benchmark.
Dispositivos Android: corrente e tensão foram lidas das APIs do sistema sob fases controladas de repouso/carga. A instrumentação completa e as janelas de amostragem estão resumidas na Tabela 4.

A potência incremental foi estimada como $\Delta P = P_{load} - P_{idle}$, e a energia por inferência como $E_{inf} = \Delta P/\text{vazão}$.

A Tabela 3 detalha os três dispositivos Android (A–C) usados na campanha. Como a inferência executa na CPU por meio do interpretador TFLite (XNNPACK, sem delegate de GPU/NNAPI), a configuração dos clusters de CPU e a memória disponível são os recursos relevantes para a carga de IA; as GPUs são listadas apenas por completude.

O envelope de implantação resultante combina vazão e energia incremental por inferência: cenários de alta taxa favorecem a execução em smartphones e SBCs, enquanto o sensoriamento autônomo de baixa taxa ainda pode ser suportado em hardware da classe microcontrolador.

6. RESULTADOS EXPERIMENTAIS

6.1 Desempenho de Predição

A Tabela 5 resume o desempenho macro em um benchmark com múltiplas sementes ($n = 10$), reportando média

Tabela 3. Especificações dos dispositivos Android (dados do fabricante; a RAM entre parênteses é o MemTotal reportado pelo sistema).

	Android A	Android B	Android C
Aparelho	Redmi Note 12	Galaxy A56 5G	Redmi Note 11S
Modelo	23021RAAEG	SM-A566E	2201117SG
SoC	Snapdragon 685	Exynos 1580	Helio G96
Litografia	6 nm	4 nm	12 nm
CPU	4×A73 2,8	1×A720 2,9	2×A76 2,05
(GHz)	4×A53 1,9	3×A720 2,6	6×A55 2,0
		4×A520 1,95	
GPU	Adreno 610	Xclipse 540	Mali-G57 MC2
RAM	6 GB (5,77)	8 GB (7,60)	6 GB (5,86)
Android	15	16	13

Tabela 4. Configuração medida e janelas de amostragem por plataforma.

Plataforma	Fonte	N_{idle}	N_{load}
ESP32 (MicroPy)	INA219	50	50
Raspberry Pi 4B	INA219	97	440
Android (A-C)	Telem. sistema	200	200

e desvio-padrão. Random Forest e LSTM obtiveram os menores erros médios, enquanto a SNN proposta permaneceu competitiva e substancialmente mais estável que a linha de base MLP.

Tabela 5. Desempenho de predição multimodal com múltiplas sementes (métricas macro).

Modelo	MAE macro	RMSE macro	R^2 macro
Random Forest	$\mathbf{0.409 \pm 0.062}$	0.557 ± 0.086	$\mathbf{0.335 \pm 0.131}$
LSTM	0.428 ± 0.059	$\mathbf{0.548 \pm 0.073}$	0.313 ± 0.139
SNN (proposta)	0.447 ± 0.064	0.566 ± 0.072	0.291 ± 0.146
MLP	0.781 ± 0.193	0.983 ± 0.178	-5.460 ± 5.220

Embora o Random Forest tenha alcançado o menor MAE, a SNN demonstrou desempenho preditivo competitivo, viabilizando a implantação em dispositivos de borda de baixo consumo, o que é essencial para cenários de monitoramento ambiental remoto. O ranqueamento indica que a SNN não é o modelo de menor erro em termos absolutos, mas permanece em uma faixa competitiva, com robustez materialmente melhor que a do MLP neste regime de poucos dados.

Para quantificar a incerteza, foram calculados intervalos de confiança de 95% (distribuição t, $n = 10$ sementes) para todas as métricas macro. Para o MAE macro: SNN [0,399; 0,495], Random Forest [0,362; 0,456], LSTM [0,384; 0,472] e MLP [0,636; 0,926]; para o R^2 macro: SNN [0,181; 0,401], Random Forest [0,237; 0,434], LSTM [0,209; 0,418] e MLP [−9,396; −1,524]. Os intervalos de SNN, Random Forest e LSTM se sobrepõem substancialmente, enquanto o MLP fica claramente separado.

Complementando o teste de sinais reportado na submissão original, testes de Wilcoxon pareados exatos sobre as dez sementes pareadas não mostram diferença significativa entre SNN e Random Forest (MAE $p = 0{,}064$; RMSE $p = 0{,}846$; R^2 $p = 0{,}922$) nem entre SNN e LSTM (MAE $p = 0{,}105$; RMSE $p = 0{,}131$; R^2 $p = 0{,}232$), enquanto a SNN supera significativamente o MLP em todas as métricas ($p = 0{,}002$). Um teste de Friedman sobre os quatro modelos é significativo (MAE: $\chi^2(3) = 19{,}56$, $p < 0{,}001$), com postos médios de 1,7 (Random Forest), 1,9 (LSTM), 2,4 (SNN) e 4,0 (MLP), confirmando que a diferença global é causada pelo MLP, e não pela separação entre os três modelos líderes.

6.2 Desempenho por Alvo

A Tabela 6 detalha o comportamento por alvo. Os três modelos líderes alcançam boa predição de pH ($R^2 \approx 0{,}67$–$0{,}72$) e erro de turbidez comparável, enquanto o OD exibe R^2 médio negativo para todos os modelos, incluindo o Random Forest. Isso é consistente com a análise de correlação da Tabela 1: o OD é fracamente correlacionado com todos os atributos de entrada disponíveis, de modo que a dificuldade é atribuível ao conjunto de atributos, e não à escolha do modelo.

Tabela 6. MAE e R^2 por alvo (média sobre 10 sementes); as células mostram MAE / R^2.

Modelo	pH	OD	TURB
SNN (proposta)	0.125 / 0.670	0.204 / −0.162	1.012 / 0.364
Random Forest	0.097 / 0.715	0.203 / −0.063	0.926 / 0.354
LSTM	0.112 / 0.673	0.203 / −0.154	0.968 / 0.422
MLP	0.777 / −13.39	0.352 / −3.021	1.214 / 0.032

6.3 Ablação do Aumento de Dados

Para quantificar o impacto do aumento de dados, comparamos o treinamento da SNN sem aumento (fator 1) e com aumento ×10 (ruído gaussiano, $\sigma = 0{,}01$) sob o mesmo protocolo em cinco sementes (7, 13, 21, 42, 84). O aumento reduziu o MAE macro de $0{,}496 \pm 0{,}060$ para $0{,}483 \pm 0{,}075$ (redução de 2,53%), com leve melhora do R^2 macro ($0{,}254 \rightarrow 0{,}256$) e RMSE macro praticamente inalterado ($0{,}615 \rightarrow 0{,}617$). O ganho por alvo mais relevante foi no MAE de turbidez ($1{,}139 \rightarrow 1{,}102$), apoiando o aumento de dados como estratégia prática de estabilização para este tamanho de conjunto.

6.4 Sensibilidade aos Pesos dos Alvos

Como a turbidez é o alvo mais difícil, também avaliamos uma pequena varredura de pesos da perda na SNN para quantificar o compromisso entre ajuste global e otimização focada em TURB. A Tabela 7 mostra que aumentar o peso de TURB pode reduzir o MAE_{TURB}, mas com leve queda do R^2 global.

Tabela 7. Varredura de pesos da perda na SNN (10 sementes).

Pesos (pH, OD, TURB)	MAE macro	MAE TURB	R^2 macro
(0.20, 0.20, 0.60)	**0.447**	1.012	**0.291**
(0.15, 0.15, 0.70)	0.452	1.022	0.289
(0.10, 0.10, 0.80)	0.454	1.028	0.288
(0.05, 0.15, 0.80)	0.448	**1.006**	0.280

6.5 Comportamento Predito vs. Real

A Figura 4 complementa as métricas agregadas mostrando a concordância ponto a ponto entre valores preditos e observados para cada alvo. pH e OD concentram-se mais próximos da linha de identidade, enquanto a turbidez apresenta maior dispersão, de forma consistente com sua maior contribuição de erro nas tabelas anteriores. Para o OD em particular, a concordância visual deve ser lida em conjunto com a Tabela 6: a baixa variância do OD no conjunto de dados (Tabela 2) mantém os erros absolutos pequenos, mas a fraca correlação entrada–alvo limita a variância explicada para todos os modelos avaliados, e não apenas para a SNN.

6.6 Resultados Espaciais e Índice de Poluição

A interpolação IDW foi usada para converter predições pontuais em superfícies espaciais contínuas, melhorando a interpretação ambiental para além das métricas pontuais. Como mostra a Figura 5, os mapas resultantes evidenciam comportamento espacial não uniforme de pH, oxigênio dissolvido e turbidez, e indicam microzonas candidatas para inspeção de campo priorizada.

Para apoiar a triagem operacional, um índice composto de poluição foi calculado a partir das predições multimodais e normalizado para [0,1], em que valores mais altos indicam pior condição relativa dentro do conjunto analisado. Como ilustra a Figura 6, a representação em nível de ponto e sua estimativa espacial por IDW sobre o mapa-base OSM fornecem uma ferramenta visual direta para a identificação de áreas críticas.

6.7 Consumo de Energia e Latência

A Tabela 8 reporta a energia incremental por inferência e a vazão nas plataformas de implantação. O ESP32 é viável para cenários autônomos de baixa taxa, mas apresenta maior energia por inferência devido à vazão limitada. Raspberry Pi e dispositivos Android fornecem mJ/inf muito menores em configurações de alta vazão.

Tabela 8. Latência/vazão e energia incremental nas plataformas.

Plataforma	Vazão (amostras/s)	ΔP (W)	E (mJ/inf)
ESP32 (MicroPy)	5.0	0.056	11.204
Raspberry Pi 4B	4670.50	0.239	0.0512
Android A	12337.40	0.128	0.0104
Android B	30905.08	0.468	0.0151
Android C	16121.71	0.046	0.00285

A Figura 7 compara a energia incremental por inferência entre plataformas em escala logarítmica: o ESP32 tem o maior custo energético por predição, principalmente devido à sua baixa vazão, enquanto Raspberry Pi e dispositivos Android operam em uma faixa de mJ/inf muito menor. Entre as plataformas móveis, maior vazão nem sempre implica menor energia por inferência, reforçando que a seleção de plataforma deve considerar conjuntamente a velocidade de processamento e o comportamento da potência incremental.

A Figura 8 resume o envelope de implantação multicritério ao colocar vazão, latência inversa, energia inversa e referência preditiva no mesmo quadro, e reforça que nenhuma plataforma domina simultaneamente todos os objetivos. Os dispositivos Android e o Raspberry Pi ocupam um envelope mais amplo nos eixos relacionados à resposta, favorecendo amostragem temporal mais densa e fluxos de campo interativos; o ESP32 contrai-se nesses eixos, mas permanece relevante para operação esparsa, autônoma e totalmente offline. A figura deve, portanto, ser lida como um mapa de implantação, e não como um ranqueamento universal.

7. DISCUSSÃO

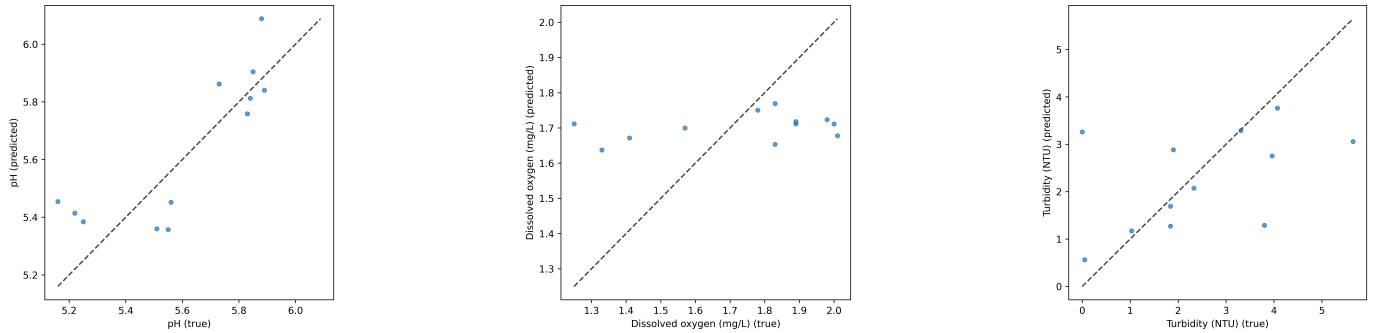
Os resultados mostram um claro compromisso entre acurácia preditiva e restrições de implantação. No benchmark com múltiplas sementes, Random Forest e LSTM alcançaram menores erros macro médios, enquanto a SNN permaneceu competitiva e claramente mais estável que o MLP. Os resultados de Wilcoxon e Friedman, junto com os intervalos de confiança sobrepostos, indicam que Random Forest, LSTM e SNN são estatisticamente indistinguíveis neste conjunto de dados, o que reforça que a SNN deve ser interpretada como uma alternativa robusta orientada à borda, e não como um modelo de melhor acurácia universal. Do ponto de vista metodológico, a configuração multimodal mostrou-se valiosa porque mantém alvos fisicamente relacionados em um único pipeline de inferência e simplifica a lógica de decisão subsequente em aplicações de campo.

Da perspectiva de sistemas, o comportamento das plataformas é heterogêneo: o Dispositivo B alcançou a maior vazão, o Dispositivo C obteve a menor energia incremental por inferência e o ESP32 forneceu viabilidade offline completa a taxas de processamento muito menores. Como a potência de base das plataformas varia com a arquitetura e o comportamento do sistema operacional, a energia por inferência combinada com a vazão é um critério mais acionável do que watts absolutos isoladamente. A ablação do aumento de dados mostrou melhora modesta mas consistente do MAE macro (2,53%) e ganho em turbidez, indicando que a expansão sintética controlada ajuda a estabilizar o treinamento neste regime de poucas amostras.

7.1 Diretrizes Práticas de Implantação

Os resultados combinados permitem uma diretriz simples de implantação para equipes de campo: para amostragem temporal densa, atualizações frequentes de mapas ou painéis quase em tempo real, a execução em smartphones ou SBCs é preferível; para verificações periódicas esparsas com estrita simplicidade de hardware, o ESP32 permanece viável e operacionalmente atraente, apesar dos maiores valores de mJ/inf.

Um segundo ponto prático é a política de seleção de modelos: em cenários de campo restritos, selecionar apenas pelo MAE mínimo pode ser subótimo. Um critério melhor é um envelope multiobjetivo que combine erro de predição aceitável, comportamento estável entre sementes, vazão da plataforma e energia incremental por inferência, extensível com restrições como orçamento de bateria e cadência de telemetria.



(a) pH (b) OD (c) TURB

Figura 4. Valores preditos vs. reais na SNN multimodal para pH, oxigênio dissolvido e turbidez. (Figura ampliada para a largura total da página nesta revisão, para legibilidade dos eixos.)

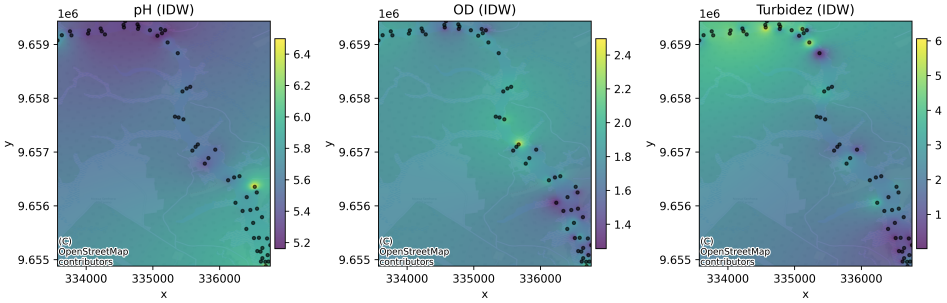


Figura 5. Superfícies interpoladas por IDW para pH, oxigênio dissolvido e turbidez a partir dos pontos amostrados. (Figura ampliada para a largura total da página nesta revisão, para legibilidade dos eixos.)



(a) Índice de poluição nos pontos amostrados. (b) Superfície IDW do índice.

Figura 6. Estimativa espacial do índice composto de poluição a partir das predições multimodais (escala normalizada $[0, 1]$) sobre mapa-base OpenStreetMap (UTM 21S). (Figura ampliada para a largura total da página nesta revisão, para legibilidade dos eixos.)

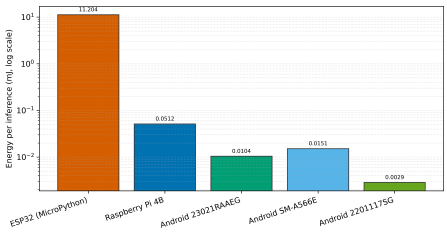


Figura 7. Comparação da energia por inferência (escala logarítmica). (Figura ampliada nesta revisão para legibilidade dos eixos.)

A escolha da SNN em vez do Random Forest merece justificativa explícita, já que o Random Forest alcançou o menor MAE médio. Primeiro, a diferença de acurácia não é estatisticamente significativa: os testes de Wilcoxon e os intervalos de confiança mostram sobreposição completa entre os dois modelos. Segundo, a SNN oferece propriedades que o Random Forest não possui: computação orientada a eventos cujo custo escala com a atividade de pulsos, um único modelo denso compacto que exporta diretamente para ONNX/TFLite em todas as três classes de plataforma, e compatibilidade futura com aceleradores neuromórficos, nos quais a execução pulsada esparsa pode

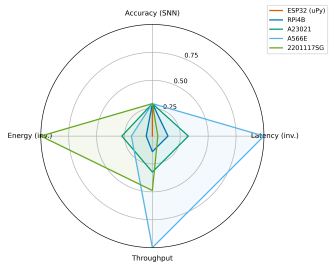


Figura 8. Comparação da implantação da SNN entre plataformas usando critérios normalizados (vazão, latência inversa, energia inversa e referência preditiva). (Figura ampliada nesta revisão para legibilidade dos eixos.)

reduzir a energia bem abaixo das medições em CPU aqui reportadas. Terceiro, o parâmetro de codificação temporal T fornece um controle ajustável de acurácia–energia sem contrapartida em comitês de árvores. A SNN é, portanto, selecionada não como o modelo de menor erro, mas como o modelo estatisticamente equivalente com o melhor envelope de implantação.

Quanto a Edge AI versus Cloud AI, o compromisso vai além da computação bruta. A inferência em nuvem oferece modelos maiores e atualizações mais simples, mas em implantações remotas na Amazônia adiciona a energia de rádio, que tipicamente domina o orçamento por amostra, latência e disponibilidade atreladas a enlaces intermitentes, custos recorrentes de conectividade e exposição de dados ambientais brutos a infraestrutura de terceiros. A inferência de borda totalmente offline inverte esse perfil: a energia é limitada pela computação local (aqui medida na escala de μJ a mJ por inferência), o monitoramento continua durante interrupções e apenas resultados agregados precisam de sincronização eventual. Um padrão híbrido — triagem local com consolidação oportunista em nuvem — é uma evolução natural do presente pipeline.

7.2 Interpretação de Erros e Validade

Os gráficos de predito vs. real indicam um claro perfil de erro dependente do alvo: pH e OD seguem a tendência de identidade com menor dispersão, enquanto a turbidez exibe espalhamento mais amplo. Esse comportamento é coerente com a heterogeneidade de águas doces e reforça que a turbidez deve ser interpretada com margens de confiança mais amplas no uso operacional. Da perspectiva de aplicação, essa assimetria apoia uma estratégia de decisão em camadas: tratar pH e OD como sinais de triagem de curto prazo mais fortes, e usar a turbidez primariamente para sinalizar zonas candidatas a amostragem adicional, e não como gatilho isolado. Para o oxigênio dissolvido especificamente, a análise por alvo mostra que nenhum modelo avaliado alcança R^2 médio positivo, o que aponta para uma limitação do conjunto de atributos, e não da modelagem: as entradas atuais carregam pouca informação relacionada ao OD ($|r| \leq 0{,}24$). Melhorar a predição de OD exigirá, portanto, enriquecer a modalidade de entrada — p. ex., condutividade, potencial de oxirredução, clorofila ou perfis diários de temperatura — em vez de mais ajuste de modelo.

As ameaças à validade permanecem centradas no tamanho amostral e na representatividade regional. Embora o aumento de dados, a avaliação com múltiplas sementes e o benchmarking multiplataforma tenham melhorado a robustez, a generalização mais ampla ainda requer campanhas em múltiplas estações e múltiplos sítios, com protocolos de aquisição harmonizados e validação externa repetida. A transferibilidade para outras regiões deve ser enquadrada em nível de pipeline, e não dos pesos treinados: os gradientes espaciais aprendidos são específicos do Lago do Serpa, de modo que a aplicação direta do modelo ajustado a outro lago não deve preservar a acurácia. O que se transfere é a metodologia — projeto de atributos, política de aumento, protocolo estatístico e pilha de implantação —, que pode ser retreinada localmente a partir de uma campanha comparavelmente pequena em um novo sítio. Estratégias de ajuste fino entre sítios e de adaptação de domínio estão planejadas para quantificar explicitamente esse custo de transferência. A reprodutibilidade é uma força prática deste pipeline: o protocolo de modelagem, a avaliação baseada em sementes e as medições de implantação offline são explícitos e portáveis, permitindo replicação direta em outros contextos de baixa conectividade. Além das métricas preditivas, a implantação no Raspberry Pi alcançou inferência submilissegundo e a validação no ESP32 confirmou execução offline autônoma sob recursos restritos, reforçando que a inferência local é praticável em perfis de borda heterogêneos.

8. CONCLUSÃO

Este artigo apresentou um pipeline SNN multimodal offline com consciência energética para a predição da qualidade da água em um contexto amazônico de monitoramento na borda. A abordagem proposta demonstrou viabilidade prática do treinamento à implantação, incluindo interpretação geoespacial e benchmarking multiplataforma de latência/energia. Os resultados indicam que a inferência neuromórfica é implantável sob restrições reais de hardware, com compromissos mensuráveis e específicos por plataforma entre vazão e energia por inferência. Embora nem sempre seja a melhor em MAE absoluto, a SNN permanece uma opção robusta quando o processamento temporal orientado a eventos e a compatibilidade com a borda são requisitos de primeira ordem.

As ameaças à validade devem ser explicitamente consideradas na interpretação destes achados. O principal risco à validade interna é o tamanho limitado do conjunto de dados original de campo, que pode aumentar a sensibilidade à partição e tornar pequenas diferenças de métricas instáveis entre partições; isso foi mitigado por avaliação com sementes repetidas, aumento de dados conservador e relato por alvo, mas não totalmente eliminado. A validade externa também é limitada pela diversidade hidrológica entre sub-regiões amazônicas, de modo que afirmações regionais mais amplas requerem campanhas em múltiplos sítios e estações, com protocolos de aquisição harmonizados. Trabalhos futuros incluem aquisição de campo mais ampla ao longo de regimes sazonais, validação externa em sistemas de água doce e lagos adicionais, e co-otimização

mais profunda dos parâmetros de codificação e dos modos de execução do hardware para melhor equilíbrio energia-desempenho. As extensões metodológicas planejadas incluem validação cruzada k-fold completa no conjunto de dados ampliado, uma comparação sistemática de estratégias de aumento de dados além da perturbação gaussiana, a medição do consumo de energia de Random Forest, LSTM e MLP sob o mesmo protocolo de repouso/carga usado para a SNN em dispositivos idênticos, e modalidades de entrada enriquecidas para tratar a limitação do oxigênio dissolvido identificada na análise por alvo. De forma geral, este estudo demonstra que modelos neuromórficos podem apoiar o monitoramento ambiental prático em regiões remotas, viabilizando inteligência de borda com consciência energética para a predição da qualidade da água na Amazônia.

AGRADECIMENTOS

Os autores agradecem ao Laboratório de Automação, Visão Computacional, Inteligência Artificial e Robótica (NAVIR), ao Programa de Pós-Graduação em Ciência, Tecnologia e Saúde (PPGCTS) e à Universidade Federal do Amazonas (UFAM) pelo apoio institucional.

REFERÊNCIAS

Ahmed, A.N. et al. (2019). Machine learning methods for better water quality prediction. *Journal of Hydrology*, 578, 124084.

Al-Adhaileh, M.H. and Alsaade, F.W. (2021). Modelling and prediction of water quality by using artificial intelligence. *Sustainability*, 13(8), 4259.

Al-Shareeda, M.A., Mohammed Ali, A., Adel Hammoud, M., Haider Muhammad Kazem, Z., and Aqeel Hussein, M. (2025). Secure iot-based real-time water level monitoring system using esp32 for critical infrastructure. *Journal of Cyber Security and Risk Auditing*, 2025(2), 44–52.

Aral, A. (2024). The promise of neuromorphic edge ai for rural environmental monitoring. *Environmental Data Science*, 3, e34.

Aribe Jr., S.G. (2025). Spiking neural networks: The future of brain-inspired computing. *International Journal of Engineering Trends and Technology*, 73(10), 32–48.

Azadi, B., Anzengruber-Tanase, B., Sopidis, G., Haslgrübler, M., and Ferscha, A. (2025). Towards an energy-efficient and sustainable iiot using embedded neuromorphic ai. In *Proceedings of the 15th International Conference on the Internet of Things*, IOT '25, 237–244. Association for Computing Machinery, New York, NY, USA.

Chadalavada, S., Yaman, S., Sengur, A., Hafeez-Baig, A., Tan, R.S., Datta Barua, P., Deo, R.C., Kobayashi, M., and Rajendra Acharya, U. (2025). Gated-lnn: Gated liquid neural networks for accurate water quality index prediction and classification. *IEEE Access*, 13, 69500–69512.

El-Shafeiy, E. et al. (2023). Real-time anomaly detection for water quality sensor monitoring based on multivariate deep learning technique. *Sensors*, 23(20), 8613.

Huijbregts, L., Liu, H.H., Detterer, P., Hamdioui, S., Yousefzadeh, A., and Bishnoi, R. (2024). Energy-efficient snn architecture using 3nm finfet multiport sram-based cim with online learning. In *Proceedings of the 61st ACM/IEEE Design Automation Conference*, DAC '24. Association for Computing Machinery, New York, NY, USA.

Kalaivanan, K. and Vellingiri, J. (2022). Survival study on different water quality prediction methods using machine learning. *Nature Environment and Pollution Technology*, 21(3), 1259–1267.

Lamrini, M. et al. (2024). Towards reliability in smart water sensing technology: Evaluating classical machine learning models for outlier detection. *Sensors*, 24(13), 4084.

Liu, P. et al. (2019). Analysis and prediction of water quality using lstm deep neural networks in iot environment. *Sustainability*, 11(7), 2058.

Lowe, M., Qin, R., and Mao, X. (2022). A review on machine learning, artificial intelligence, and smart technology in water treatment and monitoring. *Water*, 14(9), 1384.

Palani, S., Liong, S.Y., and Tkalich, P. (2008). An ann application for water quality forecasting. *Marine Pollution Bulletin*, 56(9), 1586–1597.

Pan, D., Deng, Y., Yang, S.X., and Gharabaghi, B. (2025). Recent advances in remote sensing and artificial intelligence for river water quality forecasting: A review. *Environments*, 12(5), 158.

Pyo, J. et al. (2023). Long short-term memory models of water quality in inland water environments. *Water Research X*, 21, 100207.

Qi, C., Huang, S., and Wang, X. (2020). Monitoring water quality parameters of taihu lake based on remote sensing images and lstm-rnn. *IEEE Access*, 8, 188062–188074.

Rahu, M.A. et al. (2023). Toward design of internet of things and machine learning-enabled frameworks for analysis and prediction of water quality. *IEEE Access*, 11, 1–15.

Rosero-Montalvo, P.D., López-Batista, V.F., Riascos, J.A., and Peluffo-Ordóñez, D.H. (2020). Intelligent wsn system for water quality analysis using machine learning algorithms: A case study (tahuando river from ecuador). *Remote Sensing*, 12(12), 1988.

Vasconcelos Assunção, F., Barros, A., Silva Alegria, R.C., Araújo, E.d.S., Ramos, A.M., Ivanov, C., de Lucena Junior, V.F., and Silva, V. (2026). Georeferenced multimodal water quality dataset from lago do serpa (amazon, brazil).

Wu, J. and Wang, Z. (2022). A hybrid model for water quality prediction based on an artificial neural network, wavelet transform, and long short-term memory. *Water*, 14(4), 610.

Yan, X. et al. (2024). A comprehensive review of machine learning for water quality prediction over the past five years. *Journal of Marine Science and Engineering*, 12(1), 159.

Zulkifli, C.Z. et al. (2022). Iot-based water monitoring systems: A systematic review. *Water*, 14(21), 3621.