II ENCONTRO CIENTÍFICO E TECNOLÓGICO DO HUGV
— I SEMINÁRIO CONECTANDO SABERES

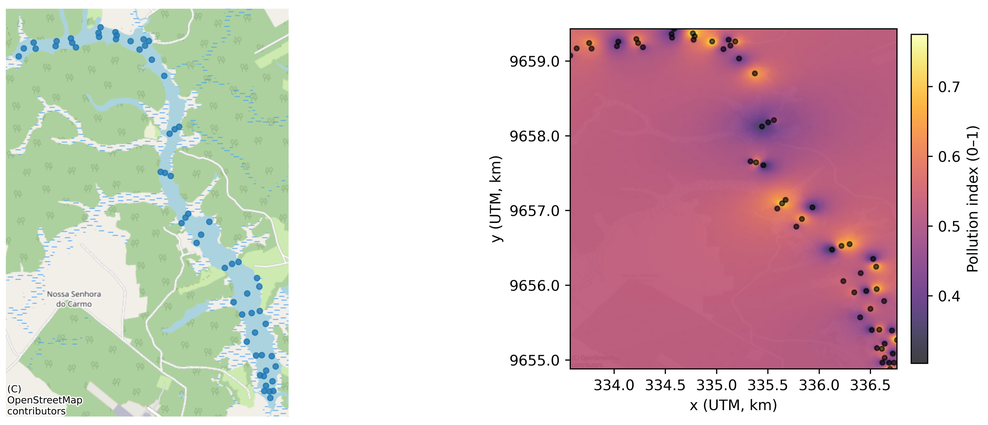
PREDIÇÃO DA QUALIDADE DA ÁGUA COM INFERÊNCIA NEUROMÓRFICA MULTIMODAL OFFLINE NA BORDA

Versão para avaliação cega

EIXO TEMÁTICO: Pesquisa Científica e Tecnológica

1. INTRODUÇÃO

O monitoramento da qualidade da água em áreas remotas da Amazônia enfrenta conectividade intermitente, custos logísticos e restrições de energia. Avaliamos uma *spiking neural network* (SNN) multimodal para predizer pH, oxigênio dissolvido (OD) e turbidez com inferência local e offline no Lago do Serpa, Itacoatiara–AM.



(a) Pontos de amostragem **(b)** Índice de poluição estimado

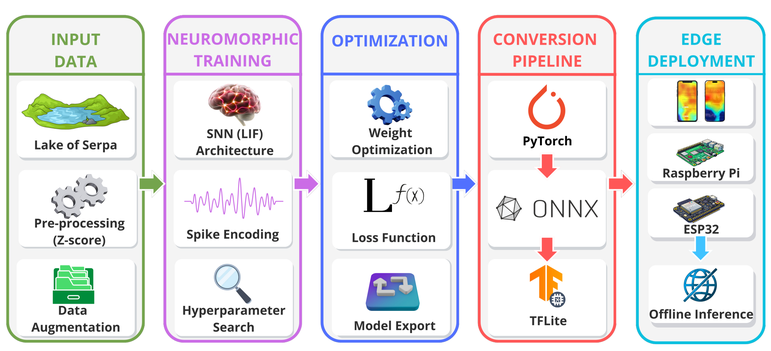
Figura 1. Área de estudo no Lago do Serpa e representação espacial do índice de poluição composto estimado. *Fonte: Dados de campo, interpolação IDW e base OpenStreetMap.*

2. OBJETIVOS

- Predizer pH, OD e turbidez com entradas físico-químicas e georreferenciadas.
- Avaliar a robustez com poucos dados, aumento gaussiano e dez sementes.
- Verificar a implantação offline em ESP32, Raspberry Pi e Android.

3. MÉTODOS

- **Dados:** 60 amostras georreferenciadas; treino ampliado para 600 amostras por aumento gaussiano controlado ($\sigma = 0{,}01$). As amostras sintéticas não representam novas medições de campo.
- **Entradas:** UTM, temperatura, cor aparente e índice visual de cor.
- **Modelo:** SNN $5 \to 64 \to 3$ com LIF, codificação temporal e MSE ponderada.
- **Avaliação:** dez sementes por *repeated random subsampling*; não equivale a validação k-fold completa.

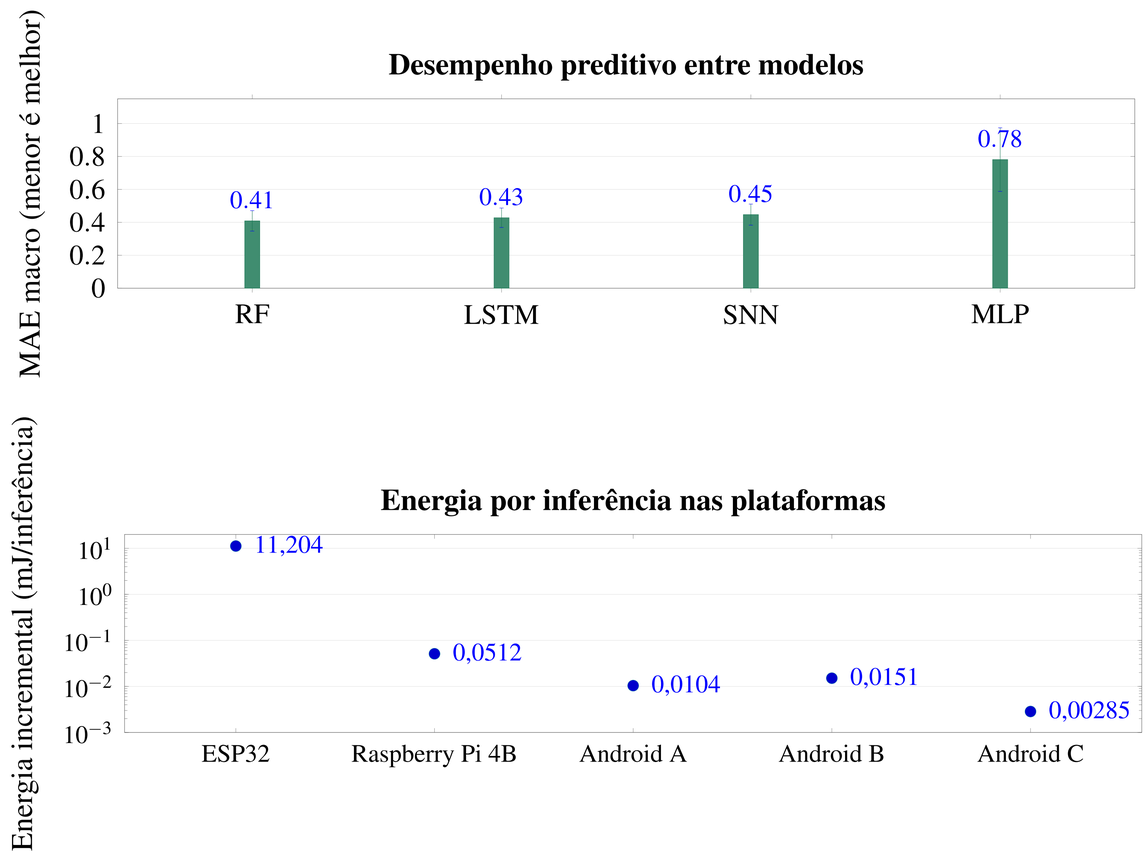


Fonte: Pipeline SNN multimodal e implantação offline.

4. RESULTADOS E DISCUSSÃO

Random Forest obteve o menor MAE macro ($0{,}409 \pm 0{,}062$); LSTM, o menor RMSE macro ($0{,}548 \pm 0{,}073$). A SNN alcançou MAE $0{,}447 \pm 0{,}064$, RMSE $0{,}566 \pm 0{,}072$ e R^2 $0{,}291 \pm 0{,}146$: desempenho competitivo para implantação na borda, sem superioridade preditiva demonstrada.

A turbidez apresenta o maior MAE absoluto por sua faixa numérica mais ampla. O OD é o alvo mais difícil em variância explicada: todos os modelos apresentaram R^2 médio negativo, coerente com sua baixa correlação com as entradas disponíveis. O pH apresentou o comportamento preditivo mais confiável. Os intervalos resumem a variabilidade entre dez sementes e não representam incerteza hidrológica populacional completa.



Fonte: MAE macro (desvio-padrão, dez sementes) e energia incremental por inferência.

5. CONCLUSÃO

- A SNN multimodal viabiliza inferência offline; pH foi o alvo mais confiável.
- OD exige cautela pela baixa variância explicada; turbidez requer margens mais amplas.
- Próximos passos: k-fold completo, novos lagos, estratégias de aumento e energia padronizada entre modelos.

REFERÊNCIAS BIBLIOGRÁFICAS

YAN, X. et al. A comprehensive review of machine learning for water quality prediction over the past five years. *Journal of Marine Science and Engineering*, v. 12, n. 1, 159, 2024.

ARAL, A. The promise of neuromorphic edge AI for rural environmental monitoring. *Environmental Data Science*, v. 3, e34, 2024.

REALIZAÇÃO E APOIO